

StockFormer: 基于 Transformer 的强化学习模型探究

2024 年 07 月 30 日

➤ **强化学习通过训练智能体直接输出投资决策。**强化学习是一种机器学习方法，通过与环境的交互来训练智能体，使其在不同状态下采取能够最大化累积奖励的行动。在强化学习中，智能体（Agent）通过与环境的互动不断学习，通过奖励和惩罚来调整其策略，以便在长期内获得最大回报。在股票市场中，强化学习可以通过市场状态的输入，不断调整交易策略，最大化长期的投资回报。强化学习在金融领域中的应用主要在状态输入，奖励函数及优化算法三个方面进行了创新。

➤ **SAC 强化学习加入多项改进以避免模型过拟合。**在 SAC 中，价值网络是一个双 Q 网络（Double DQN），即使用两个独立的 Q 网络的同时对目标函数进行估计，在目标值计算时选择最小的一个，从而降低 Q 值的高估风险，防止模型陷入局部最优或者过拟合。此外，SAC 在策略优化过程中引入了熵正则化项，熵正则化项的引入使得策略在早期阶段保持一定的随机性，避免策略网络和价值网络的学习模式过于重合以陷入局部最优，从而提高整体的策略探索能力。对于熵正则项，SAC 还引入了自适应熵系数 α ，通过优化熵系数来自动调整策略的探索程度，使得模型能够根据当前的训练情况动态调整探索与开发的平衡。

➤ **StockFormer 模型利用 Transformer 深度学习进行预测并优化交易决策。**Siyu Gao 等人在 2023 年 IJCAI 上发表的论文 StockFormer: Learning Hybrid Trading Machines with Predictive Coding 中采用 SAC 强化学习作为基础框架，并采用了 3 个 Transformer 模型分别预测市场相关状态，短期收益状态与长期收益状态作为强化学习的输入状态。然后在 SAC 强化学习中将 3 个隐状态进行合成，在组合状态空间中优化交易决策。利用沪深 300 成分股做训练，取得了优于基线 Transformer 模型的效果。

➤ **深度学习 + 强化学习较深度学习 + 组合优化收益弹性更高。**我们将 Transformer 模型作为本篇研究中的基模型构建 Transformer 因子的指数增强组合，再与 Transformer+SAC 强化学习算法形成对照。在 Transformer 模型中，我们采用日频行情与 20 个日频技术因子作为输入，预测个股周度收益排序作为因子，构建的指数增强组合 2019 年以来在中证 1000 内年化收益 17.2%，超额收益 13.8%，信息比率 2.36，表现稳定。在 StockFormer 模型中，我们替换奖励函数为超额收益-跟踪误差-交易费用，并修改前 3 个 Transformer 模型，输出每日交易行为与持仓，策略年化收益 32.7%，超额收益 29.1%，信息比率 2.57，超额收益波动率较大，但主要为上行波动，模型总体好于 Transformer 的指数增强组合。对策略持仓进行风格分析，发现模型对于市场主线识别能力较强，通过风格择时带来一定超额收益。

➤ **风险提示：**量化模型基于历史数据，市场未来可能发生变化，策略模型有失效可能。

**分析师 叶尔乐**

执业证书: S0100522110002

邮箱: yeerle@mszq.com

研究助理 韵天雨

执业证书: S0100122120002

邮箱: yuntianyu@mszq.com

相关研究

1. 量化周报: 量起来前继续保持谨慎-2024/07/28
2. 量化专题报告: 超额收益增长模型 AEG: PE 估值的内涵逻辑-2024/07/25
3. 量化分析报告: 公募“逆风”的原因解析与应对思考-2024/07/24
4. 量化周报: 普涨仍有赖于流动性整体趋势确认-2024/07/21
5. 基金分析报告: 基金季报 2024Q2: “茅宁”落幕，拥抱电子通信-2024/07/20

目录

1 什么是强化学习?	3
1.1 强化学习的概念与分类	3
1.2 强化学习在金融领域中的应用	5
1.3 软演员-评论家 (SAC) 算法	6
2 StockFormer 强化学习交易策略	8
2.1 利用 Transformer 构造市场状态	8
2.2 StockFormer 强化学习	10
3 模型实证与分析	12
3.1 Transformer 模型	12
3.2 StockFormer 强化学习模型	15
4 总结: 用“在线”与“嵌入”对抗超额下降	18
5 参考文献	20
6 风险提示	21
插图目录	22
表格目录	22

1 什么是强化学习？

1.1 强化学习的概念与分类

强化学习是一种机器学习方法，通过与环境的交互来训练智能体，使其在不同状态下采取能够最大化累积奖励的行动。其目标是通过试错学习（trial-and-error）找到最优策略，使得在长时间内累积的奖励最大化。在强化学习中，智能体（Agent）通过与环境的互动不断学习，通过奖励和惩罚来调整其策略，以便在长期内获得最大回报。在股票市场中，强化学习可以通过市场状态的输入，不断调整交易策略，最大化长期的投资回报。

图1：强化学习示意



资料来源：民生证券研究院绘制

尽管强化学习与深度学习都是机器学习方法，但其在输入数据，模型结构，模型输出与目标等方面都有所不同，总结对比如下：


图2：强化学习与深度学习对比

方面	强化学习 (RL)	深度学习 (DL)
输入数据	当前市场状态（量价等）、历史状态与奖励反馈	量价时间序列、技术指标与预测标签
模型结构	在线动态调整策略，常见结构包括DQN、SAC等	多层神经网络结构，如GRU，LSTM，Transformer等
模型输出	动作决策，如买入特定比例、卖出特定比例等	对于未来收益，排序，涨跌概率等的预测
目标	最大化长期累积奖励，如组合净值，超额净值等	最小化预测误差，最大化预测IC等

资料来源：民生证券研究院绘制

除此之外，强化学习的数据输入不是固定的。在强化学习中，数据是在智能体与环境交互的过程中得到的。强化学习是在线训练的，如果智能体不采取某个决策动作，那么该动作对应的数据就永远无法被观测到，所以当前智能体的训练数据来自之前智能体的决策结果。因此，智能体的策略不同，与环境交互所产生的数据分布就不同。


图3：强化学习训练数据的产生



资料来源：Yao Qin et al. 2017，民生证券研究院

强化学习有很多类别，主要分为依赖模型的强化学习（如 AlphaGo）与无模型强化学习。多数强化学习模型并无依赖模型，即不尝试理解或预测环境的动态（如状态转移概率和奖励结构），而是直接从与环境的交互中学习如何行动。最常见的 Q 学习及其衍生算法都属于无模型的强化学习。

图4：强化学习类别



资料来源：民生证券研究院绘制

本篇研究中我们用到了结合基于价值与基于策略强化学习的结合，即演员-评论家框架（Actor-Critic）。这类方法结合了价值模型和策略模型的方法，利用价值函数来评估策略的好坏，并根据这个评估来更新策略。Actor-Critic 是囊括一系列算法的整体架构，目前很多高效的前沿算法都属于 Actor-Critic 算法；需要明确的是，Actor-Critic 算法本质上是基于策略的算法，因为这一系列算法的目标都是优化一个带参数的策略，只是会额外学习价值函数，从而帮助策略函数更好地学习。

1.2 强化学习在金融领域中的应用

在金融领域中，强化学习被大量应用于股票交易决策制定中。在强化学习进行交易决策的框架中，主要可以在以下几个方面进行不同选择：

- **状态输入**：当前市场环境。如过去一段时间的股票量价信息，当前市场风格，基本面等；或者深度学习输出的对于股票收益的预测状态。
- **奖励函数**：交易后的累计奖励，即组合净值，超额净值，经过风险调整后的累计收益等等。
- **模型算法及结构**：Q 学习，深度 Q 网络 (DQN)，策略梯度，深度确定性策略 (DDPG)，软演员-评论家 (SAC) 等强化学习算法来训练智能体，使其学会在不同市场状态下采取最优的交易动作。同时，在强化学习中包含深度神经网络的部分，也可选取不同的神经网络模型结构。

在金融领域中，已有许多尝试使用强化学习 (RL) 方法进行交易决策的论文。这些论文主要在以上三点进行了创新。对于输入状态的定义，Yueyang Zhong 等人在 2020 年 IJCAI 上发表的论文 Data-Driven Market-Making via Model-Free Learning 中，作者用高频订单数据作为 Q 学习的输入状态，以实现高频交易决策，取得了远好于基准的表现；Yuh-Jong Hu 等人用 GRU 预测股票收益表示作为市场状态，并且在奖励函数中加入了风险调整；在模型算法及结构上的创新较多，如 Suri 等人引入了分层结构的强化学习，最终较基线模型提升了交易胜率。

图5：强化学习文献综述




资料来源：Zhong, Y 《Data-driven market-making via model-free learning》，Hu, Y 《Deep reinforcement learning for optimizing finance portfolio management》，Suri, K 《TradeR: Practical deep hierarchical reinforcement learning for trade execution》民生证券研究院绘制

1.3 软演员-评论家 (SAC) 算法

本篇研究中用到了 SAC 强化学习算法，SAC (Soft Actor-Critic) 算法是一种基于 actor-critic 框架的深度强化学习方法。相比于传统 AC 框架，SAC 采用软更新 (soft update) 策略，即使用指数移动平均 (EMA) 来更新目标 Q 网络参数，这种更新方式使得目标 Q 网络的变化更加平滑，从而提高训练过程的稳定性。SAC 模型具体网络结构如下：

图6：软演员-评论家 (SAC) 模型结构



资料来源：民生证券研究院绘制

在上图中，我们输入市场状态（个股量价，市场风格等）至 SAC 的特征解耦层 Input Embedder 与 Middleware 中，生成交易动作（高斯）分布的参数；随后将从高斯分布抽样的交易动作池，即对每只股票的买入卖出金额或比例，输入价值网络中进行评分。在 SAC 中，价值网络是一个双 Q 网络 (Double DQN)，即使用两个独立的 Q 网络同时对目标函数进行估计，在目标值计算时选择最小的一个，从而降低 Q 值的高估风险，防止模型陷入局部最优或者过拟合。虽然增加更多的 Q 网络有可能进一步防止局部过拟合，但需要权衡计算成本、收敛性和实现复杂度等因素，一般实验中不选择更多 Q 网络进行优化。


此外，SAC 在策略优化过程中引入了熵正则化项以鼓励探索。具体地，我们在目标函数中做出如下修改：

$$J_{\pi} = \sum_{t=0}^T E_{\pi_{\theta}} [r_t + \gamma E_{s_{t+1} \sim p(s_{t+1}|s_t, a_t)} [Q(s_{t+1}, a_{t+1}) - \alpha \log \pi_{\theta}(a_{t+1}|s_{t+1})]]$$

其中， $E_{\pi_{\theta}}$ 表示通过策略 π_{θ} 生成的动作的期望值， r_t 表示在时间步 t 采取动作 a_t 后得到的即时奖励，即股票收益。 γ 表示折现因子，即用于折扣未来奖励的权重，值在 0 到 1 之间， γ 越接近 1 表示越重视未来奖励，越接近 0 表示越重视即时奖励， $E_{s_{t+1} \sim p(s_{t+1}|s_t, a_t)}$ 表示在状态 s_t 采取动作 a_t 后，转移到下一个状态 s_{t+1} 的期望值， $Q(s_{t+1}, a_{t+1})$ 则表示在下一个状态下预期奖励的估计。 α 表示控制策略熵的权重，高熵策略意味着更高的探索性，而低熵策略意味着更高的确定性。

熵正则化项的引入使得策略在早期阶段保持一定的随机性，避免策略网络和价值网络的学习模式过于重合，即“演员和评论家的审美过度集中”以陷入局部最优，从而提高整体的策略探索能力。对于熵正则项，SAC 还引入了自适应熵系数 α ，通过优化熵系数来自动调整策略的探索程度，使得模型能够根据当前的训练情况动态调整探索与开发的平衡。

图7：最大熵强化学习示意图



资料来源：民生证券研究院绘制


2 StockFormer 强化学习交易策略

本篇研究我们参考了 Siyu Gao 等人在 2023 年 IJCAI 上发表的论文 *StockFormer: Learning Hybrid Trading Machines with Predictive Coding*, 论文中作者采用 SAC 强化学习作为基础框架, 并采用类 Transformer 模型的输出作为强化学习的输入状态。在第二部分中, 我们将对本论文进行详细介绍。

2.1 利用 Transformer 构造市场状态

为了预定义 SAC 强化学习输入的市场状态, 作者利用 Transformer 模型预测股票收益与市场相关状态。Transformer 模型已经被广泛应用于股票收益预测并输出因子, 最初由 Vaswani 等人在 2017 年的论文《Attention is All You Need》中提出, 其核心特点是全面依赖于注意力机制, 并行学习序列的不同子空间, 这种机制可以让模型从不同角度理解数据的同时, 大大提高训练效率。除此之外, 模型中还加入了位置编码, 使模型能够利用序列的顺序; 加入前馈网络有助于进一步转换注意力层的输出; 加入残差连接帮助避免在深层网络中训练时的梯度消失问题。


图8: Transformer 模型示意图



资料来源: Vaswani et. al. 《Attention is All You Need》, 民生证券研究院绘制

论文中，作者用到了 3 个 Transformer 网络来构造市场状态的输入，分别学习股票短期收益预测、股票中期收益预测与股票间相关性的潜在表示，这些表示共同形成了下一个训练阶段用于 SAC 强化学习投资策略的组合状态空间。在 Transformer 的应用时，作者认为多支股票序列之间时间模式的多样性增加了从原始数据中学习有效表示的难度。为了解决这一问题，作者用一组前馈网络 (Forward Feed Network) 而不是单个 FFN 来改造原始 Transformer 中的多头注意力块，其中每个 FFN 单独响应多头 (Multi-head) 注意力层输出中的一个头 (head)，在不改变整体参数数量的情况下，这种机制加强了多头注意力的原始特征解耦能力，有助于在不同子空间中建模多样的时间模式。

图9：多头前馈网络 (FFNs) 代替单个 FFN




资料来源：Siyu Gao 《StockFormer: Learning Hybrid Trading Machines with Predictive Coding》，民生证券研究院绘制

作者用改进后的 Transformer 进行了三次训练，分别预测市场相关状态，股票收益短期预测状态与长期收益预测状态。第一个 Transformer 将个股过去 252 天收盘价序列做协方差矩阵，与常见的 8 个日频技术因子拼接输入 Transformer，Transformer 分为编码器 (Encoder) 与解码器 (Decoder)。在第一个 Transformer 中，应用编码器的输出作为股票市场相关状态的预测，即解码器只起到了联合训练优化编码器的作用。

论文中选取了训练窗口期 (10 年左右) 内一直在沪深 300 内，且交易天数在 98% 以上的所有股票，数量为 88 只。协方差矩阵以股票维度的注意力替换了原本的时序维度注意力，即相关状态的训练要求训练股票不变，在预测时也须预测这 88 只股票，这也是论文中相关状态预测的局限性。

图10: Transformer 网络的分步应用




资料来源: Siyu Gao 《StockFormer: Learning Hybrid Trading Machines with Predictive Coding》, 民生证券研究院绘制

在第二和第三个 Transformer 模型中, 作者用了 10 个量价指标分别预测个股 1 日收益与个股 5 日收益。10 个量价指标分别为: 个股每日的开高低收价格, 成交量, 与这 5 个指标与前一天的差分值, 输入序列长度为 60 天。用 Transformer 解码器输出作为股票预测状态, 输入之后的 SAC 强化学习部分。

2.2 StockFormer 强化学习

StockFormer 通过预测编码从时间序列数据中提取强化学习的潜在状态, 然后在组合状态空间中优化交易决策。前文中, 我们从三个 Transformer 分支中获得三种类型的潜在表示: 关系状态 (S_t^{relat})、中期预测状态 (S_t^{long} , 5 天收益预测) 和短期预测状态 (S_t^{short} , 1 天收益预测), 随后通过多头注意力层将 S_t^{long} 与 S_t^{short} 整合为未来状态 (S_t^{future}), 最后再次通过多头注意力层将未来状态与 S_t^{relat} 合并为 SAC 的状态输入 S_t , 输入 SAC 强化学习。值得注意的是, 关系状态表示的方法并不唯一, 在下文的模型改进中, 我们将基本面信息, 即风格因子的邻接矩阵作为了相关状态的输入来源, 解决了论文模型限定股票不变的局限性。

图11: StockFormer 模型结构



资料来源: Siyu Gao 《StockFormer: Learning Hybrid Trading Machines with Predictive Coding》, 民生证券研究院绘制

在后续的 SAC 强化学习中, SAC 将输出策略函数 π , 对于每只股票决定当期的买入/卖出金额。SAC 方法包括一个演员网络 (π_θ) 和两个评论家网络 (Q_{ϕ_1} 和 Q_{ϕ_2}), 演员网络通过对高斯分布采样生成动作 (a_t), 评论家网络通过最小化贝尔曼残差来预测动作值 Q 函数, SAC 算法的目标是最大化策略的熵和期望累积奖励, 同时更新策略网络与价值网络。此外, 作者在 SAC 策略学习过程中联合训练预测编码和策略学习两个训练阶段, 以便评论家对状态值的评估可以进一步帮助从噪声和高维观测数据中挖掘交易资产之间的相关性 (上图红色虚线部分)。具体地, 作者用以下目标函数优化价值网络梯度 $J(Q)$:

$$\min_{\phi, \psi} \mathbb{E}_{(s_t, a_t) \sim D} \left[\frac{1}{2} (Q(s_t, a_t) - \hat{Q}(s_t, a_t))^2 \right], \text{ 其中}$$

$\hat{Q}(s_t, a_t) = R_t + \gamma (Q_{\phi'}(s_{t+1}, a_{t+1}) - \lambda \log \pi_\theta(a_{t+1} | s_{t+1}))$, 其中 R_t 为即时奖励, 即做出交易决策后获得的单日收益, γ 为折现因子, 代表对未来奖励的重视程度, 取值范围为 $0 \sim 1$ 。在后续应用中, 我们取 $\gamma = 1$, 即完全重视未来奖励。未来奖励为对下一期价值函数的估计减去熵正则项的惩罚, λ 为熵正则项的权重, 在 SAC 中这一系数会动态调整。

对于策略网络梯度 $J(\pi_\theta)$, 目标函数为:

$$\min_{\theta} \mathbb{E}_{s_t \sim D} [D\pi_\theta(\cdot | s_t) / Z_\phi(s_t)],$$

其中 $D\pi_\theta$ 表示经验缓冲区, $Z_\phi(s_t)$ 是 SAC 算法中自带的归一化因子, 以确保策略输出的股票持仓总和为 1。

3 模型实证与分析

3.1 Transformer 模型

首先，我们将 Transformer 模型作为本篇研究中的基模型，与后续的 Transformer+SAC 强化学习算法形成对照。在 Transformer 模型中，我们与论文中一样，采用日频行情与 20 个日频技术因子作为输入，数据输入与模型参数细节如下：

图12：数据输入模型示意

open(t-59)	high(t-59)	low(t-59)	close(t-59)	volume(t-59)	vwap(t-59)	技术因子1(t-59)	...	技术因子20(t-59)
open(t-58)	high(t-58)	low(t-58)	close(t-58)	volume(t-58)	vwap(t-58)	技术因子1(t-58)	...	技术因子20(t-58)
...	...	...	...	...	...	...	...	...
open(t-1)	high(t-1)	low(t-1)	close(t-1)	volume(t-1)	vwap(t-1)	技术因子1(t-1)	...	技术因子20(t-1)
open(t)	high(t)	low(t)	close(t)	volume(t)	vwap(t)	技术因子1(t)	...	技术因子20(t)



资料来源：民生证券研究院绘制

训练设置方面，我们基本沿用过往深度学习模型的训练设置。在 Transformer 的 Multi-head Attention 机制中，Head 数量取 10。我们取中证 1000 滚动成分股进行训练，在保证足够股票数量的同时，设置计算资源可以满足的缓冲区，以让模型充分训练。此外，中证 1000 成分股权重分布较为均衡，在强化学习中加入风险因子约束等传统风控方式会使得模型约束增加以导致一系列潜在问题，在每只股票每天都有持仓的情况下，中证 1000 内选股可以使得股票权重相对基准不会产生过大偏离。

图13：Transformer 模型参数细节

特征处理	特征X：过去60个交易日个股的高、开、低、收、成交量、VWAP，及民生金工因子库中20个技术面因子，维度为(n, 60, 26)，时序标准化 标签y：个股未来5日收益排序分位数
模型结构	Transformer: input_size=26, hidden_size=64, num_layers=2, n_heads=10 Dropout: dropout概率为0.1 MLP: 全连接层，输入维度64，输出维度1，激活函数为Tanh 损失函数：-IC
训练参数	batch_size：每天的所有中证1000成分股，epoch：50，早停：20， 学习率：0.001，优化器：Adam 半年度训练一次，训练集+验证集为6年，在其中随机取20%天数作为验证集

资料来源：民生证券研究院绘制


在技术因子的选取上，我们采用民生金工因子库中对量价刻画较为有逻辑的 20 个技术因子，包含情绪，动量等因素，使得 Transformer 模型有更多维度的输入。

表1：技术因子列表


因子名称	计算方式	数据依赖
amt_1m_3m	过去 1 个月日均成交额/过去三个月日均成交额	成交额
clo_5d_60d	5 日均价/60 日均价	收盘价
mom_1y	1 年的收益率	收盘价
swap_1m	近 21 交易日平均换手率的自然对数	换手率
corr_close_turnover	近 21 个交易日收盘价换手率相关系数	收盘价,换手率
lvol	ivol	fama_french
lvr	ivr	fama_french
lliqu	每天一个亿成交量能推动的股价涨幅	收盘价,成交额
ln_volume_mean_1m	ln_volume_mean_1m	成交量
ln_volume_std_1m	ln_volume_std_1m	成交量
turnover_std_1m	turnover_std_1m	成交量
volume_1m_div_12m	volume_1m_div_12m	成交量
volume_1m_minus_12m	volume_1m_minus_12m	成交量
volume_std_1m_div_12m	volume_std_1m_div_12m	成交量
ideal_reversal	每笔成交前十的交易日累计涨跌幅减去成交后十的交易日累计涨跌幅	收益率
up_list	涨幅排行榜	收益率
spread_bias	$-(\ln(\text{个股净值}) - \ln(\text{特征组合净值})),$ 过去 60 日标准化,特征组合由过去 252 日收益率相关系数最高的 10 只股票等权构成	收盘价
duvol	60 日上行波动率/下行波动率	涨跌幅
ncskew	负偏度系数	涨跌幅
specific_mom1	一个月残差动量	残差收益

资料来源：Wind，民生证券研究院

我们训练模型，将模型输出的收益排序作为选股因子 Transformer，模型在训练时 40 轮左右的验证集 IC 最高，损失函数变化趋势如下图。Transformer 因子的周度 RankIC 均值 10.3%，ICIR1.02，表现尚可。因模型训练只在中证 1000 成分股内，可能影响模型预测表现。

图14：模型验证集 loss 随训练轮数变化


资料来源：wind，民生证券研究院


图15：Transformer 模型因子 IC


资料来源：wind，民生证券研究院

我们用 Transformer 因子构建指数增强策略。约束主动风格暴露在 $[-0.5, 0.5]$ 之间，并约束行业暴露在 $[-0.1, 0.1]$ 之间，个股偏离 $[20\%, 500\%]$ 。在限制个

股偏离时，我们要求每只股票的权重在基准权重的 1/5 到 5 倍之间，目的是为了更好对比后续的强化学习，每支股票都有持仓。回测时，采用每周最后一个交易日的因子即预测值，每周第一个交易日调仓，取每周一 vwap 价格作为执行价，交易费用取双边千分之三，回测窗口为 2019 年至 2024 年 5 月 31 日。

图16: Transformer 模型指数增强策略表现



资料来源: Wind, 民生证券研究院

模型在中证 1000 内年化收益 17.2%，超额收益 13.8%，信息比率 2.36，表现稳定。策略分年超额收益比较均衡，今年截至 5 月底超额收益 4%，表现一般，但整体回撤控制较好。Transformer 模型为半年度训练一次，在去年年底训练时，偏好风格为前 5 年相对较优的小市值等投资策略，无法对今年大盘价值为主的稳健投资风格进行适应。除了风格控制的因素外，传统模型信号相似，交易拥挤等原因也可能导致模型近两年策略超额收益下滑。

表2: Transformer 因子指数增强组合-分年表现


年份	绝对收益	超额收益	信息比率	周度胜率	最大回撤	双边换手率 (倍)
2019	41.8%	14.8%	2.68	68.6%	-2.1%	39.45
2020	34.2%	13.8%	2.52	62.7%	-2.1%	31.23
2021	41.4%	16.8%	2.62	62.0%	-4.2%	31.39
2022	-7.1%	18.2%	2.57	70.6%	-3.3%	38.42
2023	2.5%	9.2%	1.94	67.3%	-3.3%	36.55
2024/5/31	-5.4%	4.0%	1.19	56.5%	-1.6%	15.71
平均年化	17.2%	13.8%	2.36	64.5%	-4.2%	35.50

资料来源: Wind, 民生证券研究院

3.2 StockFormer 强化学习模型

我们在论文的基础上，对 StockFormer 模型进行了一定的改进。训练集+验证集仍然为 6 年，验证集不打乱。在训练时，我们事先训练好三个 transformer 网络，即将三个不同输入的 transformer 模型保存下来，并在强化学习中进行输入。因为需要考虑到交易费用的问题，我们将由换手率带来的收益衰减增加到了奖励函数中，以让模型在日度调仓的前提下降低换手率。在模型中，我们设置训练集上每天所有交易行为，会评估一次，训练至终点时取最好的策略函数作为测试集的交易决策：

图17：最终模型结构




资料来源：民生证券研究院绘制

最终模型采用滚动每年训练的频率，在测试集上在线（每日）更新策略函数以输出下一日的交易决策。参数方面，缓冲区 $buffer_size$ 取 10^7 ，初始学习率取 $3e-4$ ， γ 取 0.999，熵正则项初始权重取 0.5，评估频率为每日。学习起始天数（更新策略函数等）为训练集上第 100 个交易日。SAC 强化学习中的演员与评论家网络均继承了论文中的 Transformer 网络。

相对深度学习的单轮训练 epoch 的概念，强化学习从组合的初始状态（学习起始天数）学习至组合的终止状态，即训练集最后一个交易日，为一集训练 (episode)。我们训练至连续 20 集验证集超额净值无增长作为模型的收敛条件，每年取验证集表现最好的策略及价值函数模型，进入下一年的在线阶段。

我们直接根据每日输出的交易行为即持仓变动生成每日持仓，初始股票权重为中证 1000 成分股权重，超额净值为 1。策略周度净值如下图所示：

图18: StockFormer 交易策略表现



资料来源: Wind, 民生证券研究院

策略年化收益 32.7%，超额收益 29.1%，信息比率 2.57，超额收益波动率较大，但主要为上行波动，模型总体好于 Transformer 的指数增强组合。分年看策略表现，策略在 2019，2020 年超额收益较高。


表3: StockFormer 交易策略-分年表现

年份	绝对收益	超额收益	信息比率	周度胜率	最大回撤	双边换手率 (倍)
2019	68.9%	36.1%	3.14	56.9%	-3.1%	78.86
2020	76.5%	49.9%	4.34	70.6%	-3.6%	64.52
2021	52.6%	26.1%	1.98	70.0%	-4.5%	69.00
2022	-7.1%	18.2%	1.40	54.9%	-5.5%	76.88
2023	11.8%	18.8%	2.49	61.2%	-3.2%	72.67
2024/5/31	5.0%	15.8%	1.59	52.2%	-1.9%	37.98
平均年化	32.7%	29.1%	2.57	60.1%	-5.5%	71.14

资料来源: Wind, 民生证券研究院

回看策略在中证 1000 上的风格因子偏离，可以体现强化学习对于市场主线的快速识别能力。策略在 2019，2020 年的风格偏离明显，尤其超配了动量和成长因子，对应了 2020 年的强势风格。在 2022，2023 市场风格主线不明显的行情下，策略风格偏离快速变换，回到无明显偏离状态，同时也有稳定的超额收益，体现了强化学习对于市场快速适应的能力。策略今年超额收益优异，超配价值低波等风格，对市场主线进行了快速识别，体现强化学习的快速适应能力。


图19: StockFormer 交易策略风格偏离



资料来源: Wind, 民生证券研究院

强化学习在周度频率上进行学习的表现并不理想，原因可能是训练集内数据粒度不够细，期数不足导致模型无法充分训练。若我们利用模型的日频仓位进行周度调仓，效果也会有所衰减，策略年化超额收益 22.6%，信息比率 1.85，超额收益最大回撤 9.5%，年化双边换手率 58.7 倍。

图20: StockFormer 交易策略表现



资料来源: Wind, 民生证券研究院

4 总结：用“在线”与“嵌入”对抗超额下降

近年来，深度学习模型如 LSTM（长短期记忆网络）和 GRU（门控循环单元）在因子选股方面的表现有所下滑，这现象可能源于多种因素。首先，这些模型在选股中的广泛应用使得它们的优势逐渐被市场消化和削弱。当越来越多的投资者使用相似的模型进行选股和交易时，市场中的套利机会变得更加稀缺，模型的边际效用也随之下降。此外，随着市场环境的不断变化，历史数据可能不再适用于当前市场情景，导致模型在预测未来表现时的准确性下降。金融市场的动态性要求模型能够及时适应新的市场条件，而传统深度学习模型为批量训练，难以快速适应市场的动态变化，导致模型超额收益有所下降。在这种市场环境中，我们未来的研究将围绕“在线学习”与多样化的“嵌入”为核心，让机器学习模型快速适应市场变化并理解不同资产中的相关性信息，获得更好的测试集表现。

本篇研究中，我们对于强化学习模型进行了初步尝试，将其与深度学习模型结合进行组合优化，相比传统因子+优化器的组合构建方式有明显收益提升。强化学习是一种机器学习方法，通过与环境的交互来训练智能体，使其在不同状态下采取能够最大化累积奖励的行动。在股票市场中，强化学习可以通过市场状态的输入，不断调整交易策略，最大化长期的投资回报。本篇研究中我们应用 SAC 强化学习作为策略依据。在 SAC 中，价值网络是一个双 Q 网络（Double DQN），即使用两个独立的 Q 网络同时对目标函数进行估计，在目标值计算时选择最小的一个，从而降低 Q 值的高估风险，防止模型陷入局部最优或者过拟合。此外，SAC 在策略优化过程中引入了熵正则化项，通过最大化策略的熵来鼓励探索，还引入了自适应熵系数 α ，通过优化熵系数来自动调整策略的探索程度，使得模型能够根据当前的训练情况动态调整探索与开发的平衡。

StockFormer 模型利用 Transformer 深度学习进行预测并优化交易决策。

Siyu Gao 等人在 2023 年 IJCAI 上发表的论文 StockFormer: Learning Hybrid Trading Machines with Predictive Coding 中采用 SAC 强化学习作为基础框架，并采用了 3 个 Transformer 模型分别预测市场相关状态，短期收益状态与长期收益状态作为强化学习的输入状态。然后在 SAC 强化学习中将 3 个隐状态进行合成，在组合状态空间中优化交易决策。利用沪深 300 成分股做训练，取得了优于基线 Transformer 模型的效果。

深度学习+强化学习较深度学习+组合优化收益弹性更高。我们将 Transformer 模型作为本篇研究中的基模型构建 Transformer 因子的指数增强组合，再与 Transformer+SAC 强化学习算法形成对照。在 Transformer 模型中，我们采用日频行情与 20 个日频技术因子作为输入，预测个股周度收益排序作为因子，构建的指数增强组合 2019 年以来在中证 1000 内年化收益 17.2%，超额收益 13.8%，信息比率 2.36，表现稳定。在 StockFormer 模型中，我们替换奖励函数为超额收益-跟踪误差-交易费用，并修改前 3 个 Transformer 模型，输出

每日交易行为与持仓，策略年化收益 32.7%，超额收益 29.1%，信息比率 2.57，超额收益波动率较大，但主要为上行波动，模型总体好于 Transformer 的指数增强组合。对策略持仓进行风格分析，发现模型对于市场主线识别能力较强，通过风格择时带来一定超额收益。

美中不足的是，强化学习在日频的较高频率交易中效果较好，将频率降为周频会导致时间窗口不足，无法充分训练等问题。未来我们将继续探索以周频甚至月频为训练环境的框架，通过重复的多次训练，构建较低频率的交易策略。

5 参考文献

1. Zhong, Y., Bergstrom, Y., & Ward, A. (2020). Data-driven market-making via model-free learning. In *Proceedings of the Twenty-Ninth International Joint Conference on Artificial Intelligence (IJCAI-20), Special Track on AI in FinTech* (pp. 4461-4468).
2. Hu, Y.-J., & Lin, S.-J. (2019). Deep reinforcement learning for optimizing finance portfolio management. In *2019 IEEE International Conference on Artificial Intelligence and Virtual Reality (AIVR)* (pp. 124-131). IEEE.
3. Suri, K., Shi, X. Q., Plataniotis, K., & Lawryshyn, Y. (2021). TradeR: Practical deep hierarchical reinforcement learning for trade execution. *arXiv*.
4. Vaswani et al. (2017). Attention is all you need. In *Proceedings of the 31st International Conference on Neural Information Processing Systems (NIPS 2017)* (pp. 5998-6008).
5. Gao, S., Wang, Y., & Yang, X. (2023). StockFormer: Learning hybrid trading machines with predictive coding. In *Proceedings of the Thirty-Second International Joint Conference on Artificial Intelligence (IJCAI-23)*.

6 风险提示

量化模型基于历史数据，市场未来可能发生变化，策略模型有失效可能。

插图目录

图 1: 强化学习示意	3
图 2: 强化学习与深度学习对比	3
图 3: 强化学习训练数据的产生	4
图 4: 强化学习类别	4
图 5: 强化学习文献综述	5
图 6: 软演员-评论家 (SAC) 模型结构	6
图 7: 最大熵强化学习示意图	7
图 8: Transformer 模型示意图	8
图 9: 多头前馈网络 (FFNs) 代替单个 FFN	9
图 10: Transformer 网络的分步应用	10
图 11: StockFormer 模型结构	11
图 12: 数据输入模型示意	12
图 13: Transformer 模型参数细节	12
图 14: 模型验证集 loss 随训练轮数变化	13
图 15: Transformer 模型因子 IC	13
图 16: Transformer 模型指数增强策略表现	14
图 17: 最终模型结构	15
图 18: StockFormer 交易策略表现	16
图 19: StockFormer 交易策略风格偏离	17
图 20: StockFormer 交易策略表现	17

表格目录

表 1: 技术因子列表	13
表 2: Transformer 因子指数增强组合-分年表现	14
表 3: StockFormer 交易策略-分年表现	16

分析师承诺

本报告署名分析师具有中国证券业协会授予的证券投资咨询执业资格并登记为注册分析师，基于认真审慎的工作态度、专业严谨的研究方法与分析逻辑得出研究结论，独立、客观地出具本报告，并对本报告的内容和观点负责。本报告清晰准确地反映了研究人员的研究观点，结论不受任何第三方的授意、影响，研究人员不曾因、不因、也将不会因本报告中的具体推荐意见或观点而直接或间接收到任何形式的补偿。

评级说明

投资建议评级标准		评级	说明
以报告发布日后的 12 个月内公司股价（或行业指数）相对同期基准指数的涨跌幅为基准。其中：A 股以沪深 300 指数为基准；新三板以三板成指或三板做市指数为基准；港股以恒生指数为基准；美股以纳斯达克综合指数或标普 500 指数为基准。	公司评级	推荐	相对基准指数涨幅 15%以上
		谨慎推荐	相对基准指数涨幅 5% ~ 15%之间
		中性	相对基准指数涨幅-5% ~ 5%之间
		回避	相对基准指数跌幅 5%以上
	行业评级	推荐	相对基准指数涨幅 5%以上
		中性	相对基准指数涨幅-5% ~ 5%之间
		回避	相对基准指数跌幅 5%以上

免责声明

民生证券股份有限公司（以下简称“本公司”）具有中国证监会许可的证券投资咨询业务资格。

本报告仅供本公司境内客户使用。本公司不会因接收人收到本报告而视其为客户。本报告仅为参考之用，并不构成对客户的投资建议，不应被视为买卖任何证券、金融工具的要约或要约邀请。本报告所包含的观点及建议并未考虑个别客户的特殊状况、目标或需要，客户应当充分考虑自身特定状况，不应单纯依靠本报告所载的内容而取代个人的独立判断。在任何情况下，本公司不对任何人因使用本报告中的任何内容而导致的任何可能的损失负任何责任。

本报告是基于已公开信息撰写，但本公司不保证该等信息的准确性或完整性。本报告所载的资料、意见及预测仅反映本公司于发布本报告当日的判断，且预测方法及结果存在一定程度局限性。在不同时期，本公司可发出与本报告所刊载的意见、预测不一致的报告，但本公司没有义务和责任及时更新本报告所涉及的内容并通知客户。

在法律允许的情况下，本公司及其附属机构可能持有报告中提及的公司所发行证券的头寸并进行交易，也可能为这些公司提供或正在争取提供投资银行、财务顾问、咨询服务等相关服务，本公司的员工可能担任本报告所提及的公司的董事。客户应充分考虑可能存在的利益冲突，勿将本报告作为投资决策的唯一参考依据。

若本公司以外的金融机构发送本报告，则由该金融机构独自为此发送行为负责。该机构的客户应联系该机构以交易本报告提及的证券或要求获悉更详细的信息。本报告不构成本公司向发送本报告金融机构之客户提供的投资建议。本公司不会因任何机构或个人从其他机构获得本报告而将其视为本公司客户。

本报告的版权仅归本公司所有，未经书面许可，任何机构或个人不得以任何形式、任何目的进行翻版、转载、发表、篡改或引用。所有在本报告中使用的商标、服务标识及标记，除非另有说明，均为本公司的商标、服务标识及标记。本公司版权所有并保留一切权利。

民生证券研究院：

上海：上海市浦东新区浦明路 8 号财富金融广场 1 幢 5F； 200120

北京：北京市东城区建国门内大街 28 号民生金融中心 A 座 18 层； 100005

深圳：广东省深圳市福田区益田路 6001 号太平金融大厦 32 层 05 单元； 518026