

基于 level2 数据图像的选股模型

华泰研究

2025 年 12 月 24 日 | 中国内地

深度研究

人工智能 99：利用图像模型分析 level2 数据

如何从海量的 level2 数据中提取有效的 Alpha 信号？本文提出一种基于图像识别的全新解决方案。该方法将高频逐笔成交与逐笔委托数据，转换为标准化的三维图像格式。其中，图像的通道数、宽度和高度分别对应订单类型、价格区间以及成交量/委托量区间，每个像素点的值则代表具备相同属性的订单笔数，像素值越高，表明该类订单出现的频率越高。随后，本研究应用强大的视觉模型 Vision Transformer (ViT) 及视频模型 Video Vision Transformer (ViViT) 对生成的图像（及图像序列）进行模式识别，从中提取人工难以捕捉的微观结构信息，并最终形成个股收益预测信号。相较于传统的时序神经网络模型，本方法能够提供差异化且有效的 Alpha 信号。

level2 数据的图像化处理

首先，针对上交所和深交所逐笔委托数据的规则差异，对上交所数据进行必要修正。随后，参考微软亚研院 MarS 论文中对订单流数据的处理思路，将逐笔成交和逐笔委托数据转换为 $15 \times 8 \times 8$ 的图像数据。具体而言，图像通道对应 15 种订单类型（如大小单、主动买卖、撤单等）；图像宽度代表按分位数划分的价格区间；图像高度代表按分位数划分的成交量/委托量区间。每个像素位置表示具有相同订单类型、价格区间及量区间的订单笔数，其值越高，表示该类订单出现的数量越多。

基于 ViT 模型的图像特征学习

本研究采用 Dosovitskiy 等人于 2021 年提出 Vision Transformer 模型。ViT 模型将输入图像分割为固定尺寸的图块，经过嵌入和位置编码后，通过标准的 Transformer 编码器学习图块之间的注意力关系，最后经全连接层输出预测结果。在本应用中，以个股最新交易日的 level2 数据图像作为模型输入，经过 ViT 模型学习图像特征，预测未来 10 日个股超额收益。在 2017 年初至 2025 年 11 月底的回测期内（周频调仓），ViT 模型的周度 RankIC 达到 10.09%，多头组合年化超额收益为 18.62%，双边换手率为 144.93%。

基于 ViViT 模型的时序图像特征学习

为进一步捕捉时序模式，本研究将过去 20 个交易日的 level2 数据图像构造成图像序列，视为四维视频数据进行处理。采用 Arnab 等人于 2021 年提出的 Video Vision Transformer 模型，在嵌入阶段使用 Tubelet Embedding 方法，将视频直接切分成固定尺寸的三维立方体，以保留局部时空特征；在编码器阶段采用 Factorised Encoder 方法，先以 Transformer 编码器学习空间注意力，再以另一个编码器学习时间注意力，从而在保持模型表现的同时降低计算复杂度。在相同回测期内，ViViT 模型的周度 RankIC 为 9.64%，多头年化超额收益为 18.26%，双边换手率降至 97.18%。

模型合成与指数增强组合表现

将 ViT 模型和 ViViT 模型进行等权合成，融合模型的周度 RankIC 进一步提升至 10.48%，多头年化超额收益达 19.66%，双边换手率为 116.83%。基于该融合模型构建指数增强组合，在 80%成分股约束以及无成分股约束两种条件下，中证 500 增强组合的年化超额收益率分别为 10.45%和 12.35%，信息比率分别为 2.19 和 2.26；中证 1000 增强组合的年化超额收益率分别为 16.26%和 17.44%，信息比率分别为 3.40 和 3.14。

风险提示：基于 level2 数据的选股模型对市场微观结构的依赖较强，未来市场变化可能导致模型失效。Transformer 架构的复杂性可能增加训练和推理时间，并带来过拟合风险。本报告不涉及标的推荐。

卢炯*, CFA

SAC No. S0570525070012

研究员

lujiiong@htsc.com

+(86) 755 8249 2388

何康, PhD

SAC No. S0570520080004


SFC No. BRB318

研究员

hegang@htsc.com

+(86) 21 2897 2202

融合因子的分层相对净值



资料来源：Wind，华泰研究

正文目录

研究导读.....	4
数据与方法.....	6
逐笔成交数据	6
逐笔委托数据	6
图像转换.....	7
ViT 模型	8
ViViT 模型	9
模型信号测试.....	12
因子测试.....	12
因子相关性分析.....	13
特征重要性分析.....	14
指数增强测试	15
中证 500 增强.....	15
中证 1000 增强.....	16
总结	19
风险提示.....	19
参考文献.....	20

图表目录

图表 1: 订单流图像转换.....	4
图表 2: level2 数据图像深度学习因子的 IC 值分析和分层回测结果汇总	5
图表 3: level2 数据图像深度学习融合因子的分层组合相对净值.....	5
图表 4: level2 数据图像深度学习融合因子的累计 RankIC	5
图表 5: 逐笔成交数据示例 (20230327, 601688.SH)	6
图表 6: 逐笔委托数据示例 (20230327, 601688.SH)	6
图表 7: 上交所逐笔委托数据修正流程图	7
图表 8: 订单流图像转换.....	7
图表 9: 图像转换方法	8
图表 10: ViT 模型网络结构	9
图表 11: ViT 模型及数据细节	9
图表 12: ViViT 模型的 Tubelet embedding	10
图表 13: ViViT 模型的 Factorised encoder	10
图表 14: ViViT 模型及数据细节	11
图表 15: level2 数据图像深度学习因子的 IC 值分析和分层回测结果汇总	12
图表 16: level2 数据图像深度学习因子的 TOP 组合相对净值.....	12
图表 17: level2 数据图像深度学习因子的累计 RankIC.....	12
图表 18: level2 数据图像深度学习融合因子的分层组合相对净值.....	13

图表 19: 深度学习因子间的相关性	13
图表 20: 深度学习因子与常见风险因子的相关性	13
图表 21: 残差信号的 IC 值分析和分层回测结果汇总	13
图表 22: 残差信号的分层组合相对净值	14
图表 23: 残差信号的累计 RankIC	14
图表 24: 特征重要性	14
图表 25: 中证 500 和中证 1000 增强组合构建细节	15
图表 26: level2 数据图像深度学习因子的中证 500 增强组合超额收益 (80%成分股)	15
图表 27: level2 数据图像深度学习因子的中证 500 增强组合超额收益 (无成分股约束)	16
图表 28: level2 数据图像深度学习因子的中证 500 增强组合回测绩效	16
图表 29: level2 数据图像深度学习因子的中证 500 增强组合逐年收益率	16
图表 30: level2 数据图像深度学习因子的中证 1000 增强组合超额收益 (80%成分股)	17
图表 31: level2 数据图像深度学习因子的中证 1000 增强组合超额收益 (无成分股约束)	17
图表 32: level2 数据图像深度学习因子的中证 1000 增强组合回测绩效	17
图表 33: level2 数据图像深度学习因子的中证 1000 增强组合逐年收益率	18

研究导读


随着人工智能技术的进步，深度学习模型在量化投资领域的应用日益广泛。其中，时序神经网络和图神经网络是当前研究的热点方向。时序神经网络（如 GRU、Transformer 等）善于刻画时间序列的动态规律，例如在华泰金工前期研究《基于全频段量价特征的选股模型》（2023.12.8）中，通过共享参数的 GRU 多任务学习模型，同时捕捉日、周、月 k 线的时序特征；《基于逐笔成交的深度学习选股模型》（2025.7.14）采用 Transformer 模型分析逐笔成交数据中的大小单、主动买卖等资金流的日内变化模式。图神经网络（如 GCN、GAT 等）则更侧重于建模股票之间的关联结构，例如在《图神经网络选股的进阶之路》（2022.4.11）报告中，通过构建残差图注意力网络，将股票收益分解为行业关联、因子关联与特异性收益三部分，深入挖掘股票间的结构化信息。

相比之下，基于图像识别的深度学习方法在量化投资领域的探索相对有限。Jiang 等人于 2023 年在 The Journal of Finance 发表论文 (Re-) Imag(in) ing price trends，尝试将股票的日频量价数据转化为“蜡烛图”图像，并利用卷积神经网络（CNN）提取特征以预测未来收益。我们在复现该研究时发现，其效果不及常见的 GRU 时序模型，这可能是因为从价格序列到蜡烛图的转换过程中损失了部分关键信息。

近期，微软亚研究院的 Li 等人于 2025 年 ICLR 上发表论文 Mars: a financial market simulation engine powered by generative foundation model，提出了一种基于生成式基础模型的金融市场模拟引擎 MarS。MarS 的核心是一个订单级别的生成式基础模型 LMM（Large Market Model）。LMM 将即时订单簿（Limit Order Book）和订单流（Order Batch）转换为令牌（Token），并借助大语言模型架构进行训练，以实现订单生成和市场模拟。该框架可应用于金融市场预测、风险检测、情景分析和强化学习环境等多个场景。

值得注意的是，MarS 在预处理阶段将订单流数据转换为图像格式。具体而言，订单流包含过去一分钟内的所有订单，每个订单具有类型、价格区间和委托量区间三种属性。这三种属性分别对应于图像的通道数（3 类订单：买单、卖单、撤单）、宽度（32 个价格区间）和高度（32 个委托量区间）。每个像素位置表示具有相同属性组合的订单数量，像素值越高，对应订单数越多。图像构造完成后，进一步通过 VQGAN 将其转换为离散令牌，并输入 LLaMA2 进行训练。

图表1：订单流图像转换



资料来源：Mars: a financial market simulation engine powered by generative foundation model，华泰研究

本报告借鉴 MarS 中对订单流的图像化处理思路，将个股单日的逐笔成交与逐笔委托数据转换为标准化图像，并采用 Vision Transformer (ViT) 模型进行训练，以构建收益预测模型。在此基础上，我们进一步引入过去 20 个交易日的图像序列，利用 Video Vision Transformer (ViViT) 模型进行时序建模。实证表明，ViT 与 ViViT 模型均表现出良好的选股能力，其中 ViViT 模型在换手率控制方面表现更优，而两者等权合成后预测效果得到进一步提升。因子的周频调仓回测表现如下。


图表2：level2 数据图像深度学习因子的 IC 值分析和分层回测结果汇总

	RankIC 均值	RankIC 标准差	RankICIR	RankIC>0 占比	TOP 组合年化超额收益率	TOP 组合信息比率	TOP 组合胜率	TOP 组合换手率
ViT 模型	10.09%	10.27%	0.98	82.87%	18.62%	3.62	85.98%	144.93%
ViViT 模型	9.64%	10.96%	0.88	82.41%	18.26%	2.80	76.64%	97.18%
融合模型	10.48%	10.95%	0.96	83.10%	19.66%	3.28	81.31%	116.83%

注：回测期为 2017/1/1~2025/11/30，周频调仓，计算 RankIC 采用 T+1~T+6 收盘价收益率，分 10 层，换手率为双边


资料来源：Wind，华泰研究

图表3：level2 数据图像深度学习融合因子的分层组合相对净值



资料来源：Wind，华泰研究

图表4：level2 数据图像深度学习融合因子的累计 RankIC



资料来源：Wind，华泰研究

数据与方法

本章基于逐笔成交与逐笔委托数据，通过预处理转换成图像格式，并利用深度学习模型训练选股信号。

逐笔成交数据

逐笔成交数据是股票每笔成交明细的记录，包含成交时间、成交价格、成交量、成交金额、买方卖方编号、买卖方向标志等交易细节。

图表5：逐笔成交数据示例（20230327，601688.SH）

	MDTime	TradeBuyNo	TradeSellNo	TradePrice	TradeQty	TradeMoney	TradeBSFlag
0	93000180	56554	227536	12.60	100.0	1260.0	2
1	93000180	68193	227536	12.60	2300.0	28980.0	2
2	93000420	229239	201286	12.61	600.0	7566.0	1
3	93000490	229861	201286	12.61	100.0	1261.0	1
4	93000800	230536	201286	12.61	200.0	2522.0	1
...	...	...	...	...	...	...	...
33106	145657250	11064682	10979090	12.61	2100.0	26481.0	1
33107	145657250	11064682	10991800	12.61	1500.0	18915.0	1
33108	145657250	11064682	10995620	12.61	16500.0	208065.0	1
33109	145657450	11065195	10995620	12.61	200.0	2522.0	1
33110	145657450	11065232	10995620	12.61	200.0	2522.0	1

资料来源：华泰数据中台，华泰研究

逐笔委托数据

逐笔委托数据是股票每笔委托明细的记录，包括委托时间、委托价格、委托量、委托类型、委托方向、订单编号等重要信息。

图表6：逐笔委托数据示例（20230327，601688.SH）

	MDTime	OrderPrice	OrderQty	OrderBSFlag	OrderType	OrderNO
0	93000040	12.96	1000.0	2	2	226921
1	93000120	12.53	2300.0	1	10	33674
2	93000240	12.97	500.0	2	2	227819
3	93000240	13.00	5000.0	2	2	228000
4	93000240	12.64	1800.0	2	2	228006
...	...	...	...	...	...	...
35333	145958590	12.64	2700.0	2	2	11133351
35334	145958670	12.64	3000.0	2	2	11133508
35335	145958800	12.64	200.0	2	2	11133752
35336	145959400	12.64	200.0	2	2	11135880
35337	145959450	12.62	92000.0	1	2	11135978

资料来源：华泰数据中台，华泰研究


需要注意的是，上交所和深交所的逐笔委托数据在规则上存在一定差异：

(1) 上交所的撤单信息记录在逐笔委托数据中，通过“委托类型”字段区分新增订单和撤回订单；深交所的撤单信息记录在逐笔成交数据中，以成交价格为 0 作为标识。

(2) 上交所的委托量为剩余委托量，代表委托报入经即时成交后的剩余数量，有 3 种情形。若委托报入后立即全部成交，只记录在逐笔成交中，不记录在逐笔委托中；若委托报入后部分成交，成交部分记录在逐笔成交中，未成交部分记录在逐笔委托中；若委托报入后未成交，只记录在逐笔委托中，等后续撮合成交后再记录逐笔成交。深交所则直接记录完整委托量，逻辑更为简明。

为了让两个交易所的逐笔委托数据保持一致，我们对上交所数据进行了修正处理。首先，根据“委托类型”字段分离出撤单信息，仅保留有效委托。随后，结合逐笔委托和逐笔成交数据，将剩余委托量还原为完整委托量，具体步骤如下。

图表7：上交所逐笔委托数据修正流程图




资料来源：华泰研究

图像转换

在数据处理与表征方面，本研究借鉴了微软亚洲研究院 MarS 论文中将订单流转换为图像格式的方法。该论文中，订单流被定义为过去一分钟内的所有订单记录，每个订单包含订单类型、价格区间和委托量区间三种属性。具体地，订单类型包括买单、卖单和撤单三类，类似于 RGB 图像的三个通道；价格被等分为 32 个区间，对应图像的宽度；委托量同样被划分为 32 个区间，对应图像的高度。图像中每个像素点的位置由价格和委托量的区间组合确定，而像素值则代表在指定时间窗口内，满足该订单类型、价格区间和委托量区间组合的订单数量。像素值越高，表明具备该属性组合的订单数量越多。

图表8：订单流图像转换



资料来源：Mars: a financial market simulation engine powered by generative foundation model, 华泰研究

基于上述思路，并结合本研究的实际预测目标与数据特点，我们对图像的构建方式进行了调整。首先，为适配低频预测任务，我们将单日内个股的全部逐笔成交与逐笔委托数据聚合，形成一张代表当日交易信息的综合图像。其次，为更细致地刻画交易行为，本研究在 MarS 论文定义的 3 种基础订单类型基础上，进一步依据主动买卖、大小单、撤单方向等多个维度进行细分，将通道数扩展为 15 个，从而构建信息更为丰富的特征表示。此外，考虑到原始论文中 32×32 的图像维度在处理日级别大量数据时可能导致计算和存储成本过高，本研究将价格与委托量的区间划分数量均压缩至 8，最终构建出维度为 $15 \times 8 \times 8$ 的图像数据。此优化在保留核心结构信息的同时，显著降低了模型训练所需的计算资源。

图表9：图像转换方法

订单属性	图像维度	定义	参数数量
订单类型	通道	成交类型：全部、主动买入、主动卖出、大买单、大卖单、小买单、小卖单，共 7 类 委托类型：买单、卖单、主动买入、主动卖出、非主动买入、非主动卖出、撤买、撤卖，共 8 类	15
价格区间	宽度	按照价格的分位数划分为 8 个区间	8
量区间	高度	按照成交量/委托量的分位数划分为 8 个区间	8

资料来源：华泰研究

示例 1：假设一笔成交订单的成交价为 12 元，位于当日价格分布的 5/8~6/8 分位数区间，成交量为 1000，位于当日成交量分布的 2/8~3/8 分位数区间。该笔订单同时属于“全部成交”（通道 0）、“主动买入”（通道 1）、“小买单”（通道 5）和“小卖单”（通道 6）四种成交类别。在图像表示中，这四个通道对应的像素位置（价格区间=5，成交量区间=2）的数值将分别增加 1，即：

$$\begin{aligned} \text{image}[0,5,2] &+= 1 \\ \text{image}[1,5,2] &+= 1 \\ \text{image}[5,5,2] &+= 1 \\ \text{image}[6,5,2] &+= 1 \end{aligned}$$


示例 2：假设一笔委托买入订单的委托价为 11 元，位于当日价格分布的 1/8~2/8 分位数区间，委托量为 50000，位于当日成交量分布的 7/8~8/8 分位数区间。该笔委托被同时归类为“买单”（通道 7）与“非主动买入”（通道 11）。在图像表示中，这两个通道对应的像素位置（价格区间=1，委托量区间=7）的数值将相应增加 1，即

$$\begin{aligned} \text{image}[7,1,7] &+= 1 \\ \text{image}[11,1,7] &+= 1 \end{aligned}$$

ViT 模型

模型方面，我们采用基于 Transformer 架构的视觉模型。2021 年 Dosovitskiy 等人提出 Vision Transformer (ViT)，将图像分割为固定大小的图像块，经嵌入与位置编码后，通过 Transformer 编码器捕捉图像块间的注意力关系，最终经全连接层输出预测。本文以个股最新交易日的 level2 数据图像作为输入，经通道内归一化处理后输入 ViT 模型，提取图像特征并预测未来 10 日超额收益。

图表10: ViT 模型网络结构



资料来源：An image is worth 16x16 words: Transformers for image recognition at scale, 华泰研究

图表11: ViT 模型及数据细节

特征和标签	特征 X: 个股最新交易日的 level2 数据图像数据。
	标签 y: 个股未来 10 个交易日 ($T+1 \sim T+11$) 的收益率。
	特征预处理: 每个通道内做归一化。
	标签预处理: 对标签进行截面 z-score 标准化。
	样本内训练数据从 2014 年开始, 每 5 个交易日采样一次, 训练集和验证集依时间先后按照 4:1 的比例划分。
模型结构	Patch: 切分为小图片, 尺寸为 2×2 , 切分后图像大小从 8×8 变成 4×4 , 展开后变成长度为 16 的序列。
	Input Embedding: 输入嵌入。
	Positional Encoding: 位置编码, 并加入一个可学习的分类 token。
	Multi-Head Attention: 多头注意力。
	Feed Forward: 全连接。
	Encoder: 每层包括多头注意力、全连接、残差连接、层标准化等。
	FC: 全连接, 输出预测。
模型其他参数	损失函数: 预测值与标签之间 IC 的相反数。
	batch_size: 5000。
	训练最大迭代轮数: 100, 早停轮数: 10。
	学习率: 0.001, 优化器: Adam。
	模型每年重新训练一次。

资料来源：华泰研究


ViViT 模型

为进一步引入时间维度信息, 本研究还采用 Video Vision Transformer (ViViT) 处理历史图像序列。2021 年 Arnab 等人提出 ViViT, 用于视频数据的建模, 其在 ViT 基础上进行了两方面的扩展:

(1) 在嵌入阶段, ViViT 需要考虑时间维度的切分, 作者提出两种做法。方法一是 Uniform Frame Sampling, 按顺序对视频进行逐帧采样, 每一帧都采用 ViT 的做法进行图像切分; 方法二是 Tubelet Embedding, 直接将视频切分成固定尺寸的三维小立方体。本研究采用方法二, 因为其更有利于捕捉局部时空特征。


(2) 在编码器阶段, 除了图像上的空间注意力外, ViViT 还需考虑时间注意力, 作者提出四种做法。方法一是 Spatio-Temporal Attention, 直接将时空序列展平, 再使用 Transformer 编码器学习自注意力, 缺点是复杂度呈平方级; 方法二是 Factorised Encoder, 先通过空间 Transformer 编码器提取空间特征, 再经时间 Transformer 编码器融合时序信息, 能够有效降低计算复杂度; 方法三是 Factorised Self-Attention, 在一个模块中先后学习空间和时间注意力, 再堆叠多个模块; 方法四是 Factorised Dot-Product Attention, 将时间和空间注意力的计算放在不同的注意力头中来实现。本研究采用方法二, 因为其能够在保证模型性能的同时显著降低计算复杂度。

图表12: ViViT 模型的 Tubelet embedding



资料来源: ViViT: A Video Vision Transformer, 华泰研究

图表13: ViViT 模型的 Factorised encoder



资料来源: ViViT: A Video Vision Transformer, 华泰研究

本文以过去 20 个交易日的 level2 数据图像序列作为输入, 经上述处理流程后, 同样输出未来 10 日超额收益的预测。

图表14: ViViT 模型及数据细节

特征和标签	特征 X: 个股过去 20 个交易日的量价视频数据。
	标签 y: 个股未来 10 个交易日 (T+1~T+11) 的收益率。
	特征预处理: 每个通道内做归一化。
	标签预处理: 对标签进行截面 z-score 标准化。
	样本内训练数据从 2014 年开始, 每 5 个交易日采样一次, 训练集和验证集依时间先后按照 4:1 的比例划分。
模型结构	Tubelet embedding: 切分为小立方体, 尺寸为 2×2×2, 切分后视频大小从 20×8×8 变成 10×4×4, 展开后变成 10×16 的时空序列。
	Input Embedding: 输入嵌入。
	Positional Encoding: 位置编码, 并加入一个可学习的分类 token。
	Multi-Head Attention: 多头注意力。
	Feed Forward: 全连接。
	Spatial Encoder: 用于空间注意力, 每层包括多头注意力、全连接、残差连接、层标准化等。
	Temporal Encoder: 用于时序注意力, 每层包括多头注意力、全连接、残差连接、层标准化等。
模型其他参数	FC: 全连接, 输出预测。
	损失函数: 预测值与标签之间 IC 的相反数。
	batch_size: 5000。
	训练最大迭代轮数: 100, 早停轮数: 10。
	学习率: 0.001, 优化器: Adam。
	模型每年重新训练一次。

资料来源: 华泰研究

本研究在英伟达 V100 显卡 (32GB 显存) 上开展训练, 以单次随机种子下的完整滚动训练为例, ViT 模型的训练耗时约为 1.5 小时, 而 ViViT 模型则需约 14 小时。

模型信号测试

本章对 ViT 和 ViViT 在测试集中的预测信号进行回测分析。为减轻随机性影响，每个模型分别使用三个随机数种子进行训练，并将三次训练结果等权集成，作为最终的因子信号用于回测。

因子测试

因子测试方法如下：

- (1) 股票池：全 A 股，剔除 ST 股票，剔除每个截面期下一交易日停牌、涨停的股票。
- (2) 回测区间：2017/1/1~2025/11/30。
- (3) 调仓周期：周频，不计交易费用。
- (4) 测试方法：IC 值分析，因子分 10 层测试。

测试结果显示，ViT 模型和 ViViT 模型各有优势。ViT 模型在预测能力上表现更强，其 RankIC 均值、RankICIR、TOP 组合超额收益及信息比率等指标均较高；ViViT 模型则表现出更低的 TOP 组合换手率，这主要得益于其输入为过去 20 个交易日的图像序列，信号在时序上具有较高的自相关性。将 ViT 与 ViViT 模型等权融合后，融合模型在 RankIC 均值、TOP 组合超额收益等关键指标上均有提升，同时换手率较 ViT 模型明显下降。


图表15：level2 数据图像深度学习因子的 IC 值分析和分层回测结果汇总

	RankIC 均值	RankIC 标准差	RankICIR	RankIC>0 占比	TOP 组合年化超额收益率	TOP 组合信息比率	TOP 组合胜率	TOP 组合换手率
ViT 模型	10.09%	10.27%	0.98	82.87%	18.62%	3.62	85.98%	144.93%
ViViT 模型	9.64%	10.96%	0.88	82.41%	18.26%	2.80	76.64%	97.18%
融合模型	10.48%	10.95%	0.96	83.10%	19.66%	3.28	81.31%	116.83%

注：回测期为 2017/1/1~2025/11/30，周频调仓，计算 RankIC 采用 T+1-T+6 收盘价收益率，分 10 层，换手率为双边


资料来源：Wind，华泰研究

图表16：level2 数据图像深度学习因子的 TOP 组合相对净值




资料来源：Wind，华泰研究

图表17：level2 数据图像深度学习因子的累计 RankIC



资料来源：Wind，华泰研究

图表18: level2 数据图像深度学习融合因子的分层组合相对净值



注：回溯期为 2017/1/1~2025/11/30

资料来源：Wind，华泰研究

因子相关性分析

相关性分析表明，ViT 与 ViViT 模型信号间的相关系数为 0.72，说明两者具有信息互补性。以团队前期研究报告《基于逐笔成交的深度学习选股模型》（2025.7.14）中的 Transformer 模型信号作为时序类模型的代表，ViT、ViViT 及两者融合模型与该时序模型信号的相关性在 0.6~0.7 之间，进一步表明图像模型所提取的信号与传统时序模型具有明显差异。此外，深度学习因子整体呈现反转、低流动性、高 beta、低估值等风格暴露，市值暴露相对较弱。

图表19: 深度学习因子间的相关性

	ViT 模型	ViViT 模型	融合模型	时序 Transformer 模型
ViT 模型		0.72	0.92	0.62
ViViT 模型	0.72		0.93	0.68
融合模型	0.92	0.93		0.69
时序 Transformer 模型	0.62	0.68	0.69	

资料来源：Wind，华泰研究

图表20: 深度学习因子与常见风险因子的相关性

	动量	市值	成交金额	换手率	beta	账面市值比
ViT 模型	-0.11	-0.06	-0.35	-0.39	0.16	0.24
ViViT 模型	-0.08	0.02	-0.28	-0.42	0.19	0.22
融合模型	-0.10	-0.02	-0.33	-0.43	0.19	0.25

资料来源：Wind，华泰研究

使用基于 level2 数据图像的融合模型信号对时序 Transformer 模型进行回归，并对回归残差进行回测。结果表明，残差仍具备稳定的选股能力，进一步证明图像模型可捕捉时序模型无法覆盖的 Alpha 信息。从特征逻辑上看，时序模型主要学习量价数据在时间维度上的演变规律，而图像模型则更侧重于从价格与成交量/委托量的联合分布及其相关性中提取信息。


图表21: 残差信号的 IC 值分析和分层回测结果汇总

	RankIC 均值	RankIC 标准差	RankICIR	RankIC>0 占比	TOP 组合年化超额收益率	TOP 组合信息比率	TOP 组合胜率	TOP 组合换手率
残差信号	3.74%	7.43%	0.50	70.37%	10.42%	2.02	71.03%	132.64%

注：回溯期为 2017/1/1~2025/11/30，周频调仓，计算 RankIC 采用 T+1~T+6 收盘价收益率，分 10 层，换手率为双边


资料来源：Wind，华泰研究

图表22：残差信号的分层组合相对净值



资料来源：Wind，华泰研究

图表23：残差信号的累计 RankIC



资料来源：Wind，华泰研究


特征重要性分析

特征重要性分析采用如下方法：针对图像数据中的每个特征通道，在单日全样本股票中对该通道数据进行随机重排，其余通道保持不变，进而计算样本外预测信号的 RankIC 变化。RankIC 下降幅度越大，说明该通道特征越重要。以下以某一随机种子下的 VIT 模型为例进行分析。

在基于逐笔成交数据构建的特征通道中，重要性排序依次为：大小单 > 主动买卖 > 全部成交。其中，大小单特征通过聚合买卖单编号进行判定，与单笔成交量存在差异，因此贡献了显著的增量信息；主动买卖特征可能与逐笔委托中的对应信息存在重叠，重要性相对较低；全部成交特征可由其他通道推算得出，信息冗余度高，因此重要性最低。

在基于逐笔委托数据构建的特征通道中，非主动卖出与非主动买入的重要性最高。这类非主动委托通常对应投资者将订单置于最优报价之后等待成交，体现其交易耐心与信心，可能包含更多具有思考性的非机械化交易信息，因此信息含量更高。

图表24：特征重要性



资料来源：Wind，华泰研究

指数增强测试

分别使用 ViT 模型、ViViT 模型及融合模型，构建中证 500 和中证 1000 指数增强组合。具体测试方法如下表。其中，成分股权重约束分别设置为不低于 80% 以及无约束两种情形。为降低调仓时点选择带来的偏差，每个因子均以相邻 5 个交易日作为调仓起始日，构建 5 条独立的调仓路径，最终取回测结果的均值。

图表25：中证 500 和中证 1000 增强组合构建细节


优化目标	最大化预期收益
成分股权重约束	场景 1：不低于 80%；场景 2：无约束
个股权重偏离上限	0.8%
风格因子约束	行业暴露<0.02, barra 暴露<0.3
换手率约束	周双边换手率上限为 30%
调仓频率和交易成本	5 日调仓，调仓当日以 vwap 价格成交，交易成本双边千分之四
调仓路径	采用相邻 5 个交易日作为调仓起始日，构建 5 条独立调仓路径的组合，取回测均值

资料来源：华泰研究

中证 500 增强

在 2017 年初至 2025 年 11 月底的回测期内，基于 ViT、ViViT 和融合模型构建中证 500 增强组合，在 80% 成分股约束下的年化超额收益率分别为 9.70%、10.05% 和 10.45%，无成分股约束下的年化超额收益率分别为 9.94%、11.70% 和 12.35%。结果表明，融合模型整体表现优于单一模型，且放宽成分股约束有助于进一步提升超额收益，但同时也伴随着跟踪误差与超额最大回撤的上升。

图表26：level2 数据图像深度学习因子的中证 500 增强组合超额收益（80%成分股）



注：回测期为 2017/1/1~2025/11/30

资料来源：Wind，华泰研究

Figure 10 is a line graph comparing the performance of three models: ViT (blue solid line), ViViT (cyan dashed line), and the Fusion model (red solid line) from 2017 to 2025. The y-axis represents performance, ranging from 0.0 to 2.0. The x-axis shows years from 2017/01 to 2025/01. The Fusion model consistently achieves the highest performance, followed by ViViT, and then ViT. All models show a general upward trend over time.

Year	ViT 模型	ViViT 模型	融合模型
2017/01	0.00	0.00	0.00
2018/01	0.10	0.10	0.15
2019/01	0.30	0.30	0.40
2020/01	0.45	0.45	0.55
2021/01	0.60	0.60	0.75
2022/01	0.75	0.80	0.95
2023/01	0.90	1.00	1.20
2024/01	1.05	1.20	1.40
2025/01	1.30	1.50	1.75

资料来源：Wind，华泰研究

	年化收益率	年化波动率	夏普比率	最大回撤	年化超额收益率	年化跟踪误差	超额收益最大回撤	信息比率	Calmar 比率	相对基准月胜率	调仓双边换手率
80%成份股											
ViT 模型	11.21%	20.84%	0.54	30.77%	9.70%	4.64%	7.23%	2.09	1.34	76.64%	33.91%
ViViT 模型	11.55%	20.93%	0.55	29.52%	10.05%	4.82%	7.66%	2.08	1.31	70.09%	33.98%
融合模型	11.97%	20.87%	0.57	29.23%	10.45%	4.77%	8.08%	2.19	1.29	74.77%	33.93%
无成份股约束											
ViT 模型	11.51%	20.72%	0.56	29.56%	9.94%	5.12%	7.69%	1.94	1.29	73.83%	34.09%
ViViT 模型	13.33%	20.63%	0.65	29.15%	11.70%	5.51%	8.98%	2.12	1.30	74.77%	34.16%
融合模型	13.98%	20.65%	0.68	29.15%	12.35%	5.47%	8.52%	2.26	1.45	77.57%	34.09%
中证 500	1.12%	21.54%	0.05	41.81%							


资料来源：Wind，华泰研究

	2017 年收益率	2018 年收益率	2019 年收益率	2020 年收益率	2021 年收益率	2022 年收益率	2023 年收益率	2024 年收益率	2025 年收益率
	80%成份股								
VIT 模型	7.48%	-22.67%	38.24%	29.52%	30.72%	-9.84%	-0.95%	9.62%	30.34%
ViViT 模型	7.43%	-21.64%	39.28%	29.63%	29.82%	-7.54%	-3.11%	10.36%	30.61%
融合模型	9.14%	-20.76%	37.13%	29.26%	31.07%	-8.35%	-2.05%	11.07%	31.36%
	无成份股约束								
VIT 模型	7.89%	-19.98%	41.58%	26.80%	27.64%	-9.83%	-1.09%	10.05%	30.84%
ViViT 模型	6.52%	-18.17%	44.79%	32.52%	28.78%	-7.90%	-2.79%	15.76%	30.72%
融合模型	9.67%	-17.53%	45.68%	29.58%	29.48%	-6.86%	-1.77%	14.50%	32.40%
中证 500	-2.24%	-33.32%	26.38%	20.87%	15.58%	-20.31%	-7.42%	5.46%	22.81%

资料来源: Wind, 华泰研究

在相同回溯期内，基于 ViT、ViViT 和融合模型构建中证 1000 增强组合，在 80%成分股约束下的年化超额收益率分别为 14.77%、16.05%和 16.26%，无成分股约束下的年化超额收益率分别为 15.82%、17.64%和 17.44%。与中证 500 增强组合相比，中证 1000 增强组合在各模型下均获得显著更高的超额收益。


图表30: level2 数据图像深度学习因子的中证 1000 增强组合超额收益 (80%成份股)



注: 回溯期为 2017/1/1~2025/11/30

资料来源: Wind, 华泰研究

图表31: level2 数据图像深度学习因子的中证 1000 增强组合超额收益 (无成份股约束)



注: 回溯期为 2017/1/1~2025/11/30

资料来源: Wind, 华泰研究

图表32: level2 数据图像深度学习因子的中证 1000 增强组合回溯绩效

	年化收益率	年化波动率	夏普比率	最大回撤	年化超额收益率	年化跟踪误差	超额收益最大回撤	信息比率Calmar 比率	相对基准月胜率	调仓双边换手率
80%成份股										
ViT 模型	12.96%	23.21%	0.56	36.61%	14.77%	4.58%	6.00%	3.22	2.46	85.98%
ViViT 模型	14.21%	23.28%	0.61	35.32%	16.05%	4.84%	5.87%	3.31	2.73	80.37%
融合模型	14.44%	23.21%	0.62	35.52%	16.26%	4.79%	6.10%	3.40	2.66	85.05%
无成份股约束										
ViT 模型	14.10%	22.96%	0.61	34.39%	15.82%	5.27%	6.39%	3.00	2.48	85.05%
ViViT 模型	15.94%	22.88%	0.70	33.71%	17.64%	5.69%	7.77%	3.10	2.27	79.44%
融合模型	15.72%	22.92%	0.69	33.88%	17.44%	5.56%	7.20%	3.14	2.42	84.11%
中证 1000	-1.86%	23.97%	-0.08	52.11%						

注: 回溯期为 2017/1/1~2025/11/30

资料来源: Wind, 华泰研究

图表33: level2 数据图像深度学习因子的中证 1000 增强组合逐年收益率

	2017 年收益率	2018 年收益率	2019 年收益率	2020 年收益率	2021 年收益率	2022 年收益率	2023 年收益率	2024 年收益率	2025 年收益率
80%成份股									
ViT 模型	-2.15%	-22.05%	49.57%	38.36%	35.55%	-12.08%	0.56%	8.67%	38.04%
ViViT 模型	-2.47%	-22.42%	53.01%	32.98%	42.73%	-8.87%	0.17%	14.00%	36.36%
融合模型	0.13%	-21.53%	53.75%	35.29%	39.16%	-11.28%	1.25%	11.43%	39.29%
无成份股约束									
ViT 模型	-1.43%	-20.97%	51.88%	33.86%	36.70%	-11.22%	2.15%	11.88%	40.76%
ViViT 模型	-2.71%	-17.08%	52.09%	33.33%	38.34%	-6.47%	1.36%	15.74%	42.83%
融合模型	-0.21%	-17.53%	51.86%	32.51%	37.74%	-10.20%	2.83%	15.40%	43.53%
中证 1000	-18.49%	-36.87%	25.67%	19.39%	20.52%	-21.58%	-6.28%	1.20%	23.10%

注: 回测期为 2017/1/1~2025/11/30

资料来源: Wind, 华泰研究

总结

如何从海量的 level2 数据中提取有效的 Alpha 信号？本文提出一种基于图像识别的全新解决方案。该方法将高频逐笔成交与逐笔委托数据，转换为标准化的三维图像格式。其中，图像的通道数、宽度和高度分别对应订单类型、价格区间以及成交量/委托量区间，每个像素点的值则代表具备相同属性的订单笔数，像素值越高，表明该类订单出现的频率越高。随后，本研究应用强大的视觉模型 Vision Transformer (ViT) 及视频模型 Video Vision Transformer (ViViT) 对生成的图像（及图像序列）进行模式识别，从中提取人工难以捕捉的微观结构信息，并最终形成个股收益预测信号。相较于传统的时序神经网络模型，本方法能够提供差异化且有效的 Alpha 信号。

level2 数据的图像化处理。由于上交所和深交所的逐笔委托数据存在规则差异，首先需要上交所数据进行修正。接着，参考微软亚研院 MarS 论文中对订单流数据的处理方式，将逐笔成交和逐笔委托数据转换为 $15 \times 8 \times 8$ 的图像数据。其中，订单类型包括大小单、主动买卖、买卖单、撤买撤卖等 15 类，对应图像通道数量；价格按照分位数划分 8 个区间，对应图像宽度；成交/委托量按照分位数划分 8 个区间，对应图像高度。每个像素位置表示具有相同属性的订单数量，像素值越高，代表该类订单数量越多。

基于 ViT 模型的图像特征学习。本研究采用 Dosovitskiy 等人于 2021 年提出 Vision Transformer 模型。ViT 模型将输入图像分割为固定尺寸的图块，经过嵌入和位置编码后，通过标准的 Transformer 编码器学习图块之间的注意力关系，最后经全连接层输出预测结果。在本应用中，以个股最新交易日的 level2 数据图像作为模型输入，经过 ViT 模型学习图像特征，预测未来 10 日个股超额收益。在 2017 年初至 2025 年 11 月底的回测期内（周频调仓），ViT 模型的周度 RankIC 达到 10.09%，多头组合年化超额收益为 18.62%，双边换手率为 144.93%。

基于 ViViT 模型的时序图像特征学习。为进一步捕捉时序模式，本研究将过去 20 个交易日的 level2 数据图像构造成图像序列，视为四维视频数据进行处理。采用 Arnab 等人于 2021 年提出的 Video Vision Transformer 模型，在嵌入阶段使用 Tubelet Embedding 方法，将视频直接切分成固定尺寸的三维立方体，以保留局部时空特征；在编码器阶段采用 Factorised Encoder 方法，先以 Transformer 编码器学习空间注意力，再以另一个编码器学习时间注意力，从而在保持模型表现的同时降低计算复杂度。在相同回测期内，ViViT 模型的周度 RankIC 为 9.64%，多头年化超额收益为 18.26%，双边换手率降至 97.18%。

模型合成与指数增强组合表现。将 ViT 模型和 ViViT 模型进行等权合成，融合模型的周度 RankIC 进一步提升至 10.48%，多头年化超额收益达 19.66%，双边换手率为 116.83%。基于该融合模型构建指数增强组合，在 80%成分股约束以及无成分股约束两种条件下，中证 500 增强组合的年化超额收益率分别为 10.45%和 12.35%，信息比率分别为 2.19和 2.26；中证 1000 增强组合的年化超额收益率分别为 16.26%和 17.44%，信息比率分别为 3.40和 3.14。

未来研究可以从以下几个方面展开：（1）在日度图像基础上，构建更高频（如分钟级）的交易数据图像表示，以捕捉更精细的日内模式与动态变化；（2）探索更丰富的多模态数据表征方法，如融合时序、图像及图结构的信息；（3）针对金融市场常见的非平稳分布与噪声问题，开发更合适的数据处理与正则化方法，提升模型的泛化能力。

风险提示

基于 level2 数据的选股模型对市场微观结构的依赖较强，未来市场变化可能导致模型失效。Transformer 架构的复杂性可能增加训练和推理时间，并带来过拟合风险。本报告不涉及标的的推荐。

参考文献

- [1] Li J, Liu Y, Liu W, et al. Mars: a financial market simulation engine powered by generative foundation model[J]. arXiv preprint arXiv:2409.07486, 2024.
- [2] Dosovitskiy A. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.
- [3] Arnab A, Dehghani M, Heigold G, et al. Vivit: A video vision transformer[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 6836-6846.
- [4] Jiang J, Kelly B, Xiu D. (Re-) Imag (in) ing price trends[J]. The Journal of Finance, 2023, 78(6): 3193-3249.

免责声明

分析师声明

本人，卢炯、何康，兹证明本报告所表达的观点准确地反映了分析师对标的证券或发行人的个人意见；彼以往、现在或未来并无就其研究报告所提供的具体建议或所表达的意见直接或间接收取任何报酬。请注意，标*的人员并非香港证券及期货事务监察委员会的注册持牌人，不可在香港从事受监管活动。

一般声明及披露

本报告由华泰证券股份有限公司或其关联机构制作，华泰证券股份有限公司和其关联机构统称为“华泰证券”（华泰证券股份有限公司已具备中国证监会批准的证券投资咨询业务资格）。本报告所载资料是仅供接收人的严格保密资料。本报告仅供华泰证券及其客户和其关联机构使用。华泰证券不因接收人收到本报告而视其为客户。

本报告基于华泰证券认为可靠的、已公开的信息编制，但华泰证券对该等信息的准确性及完整性不作任何保证。

本报告所载的意见、评估及预测仅反映报告发布当日的观点和判断。在不同时期，华泰证券可能会发出与本报告所载意见、评估及预测不一致的研究报告。同时，本报告所指的证券或投资标的的价格、价值及投资收入可能会波动。以往表现并不能指引未来，未来回报并不能得到保证，并存在损失本金的可能。华泰证券不保证本报告所含信息保持在最新状态。华泰证券对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

华泰证券（华泰证券（美国）有限公司除外）不是 FINRA 的注册会员，其研究分析师亦没有注册为 FINRA 的研究分析师/不具有 FINRA 分析师的注册资格。

华泰证券力求报告内容客观、公正，但本报告所载的观点、结论和建议仅供参考，不构成购买或出售所述证券的要约或招揽。该等观点、建议并未考虑到个别投资者的具体投资目的、财务状况以及特定需求，在任何时候均不构成对客户私人投资建议。投资者应当充分考虑自身特定状况，并完整理解和使用本报告内容，不应视本报告为做出投资决策的唯一因素。对依据或者使用本报告所造成的一切后果，华泰证券及作者均不承担任何法律责任。任何形式的分享证券投资收益或者分担证券投资损失的书面或口头承诺均为无效。

除非另行说明，本报告中所引用的关于业绩的数据代表过往表现，过往的业绩表现不应作为日后回报的预示。华泰证券不承诺也不保证任何预示的回报会得以实现，分析中所做的预测可能是基于相应的假设，任何假设的变化可能会显著影响所预测的回报。

华泰证券及作者在自身所知情的范围内，与本报告所指的证券或投资标的不存在法律禁止的利害关系。在法律许可的情况下，华泰证券可能会持有报告中提到的公司所发行的证券头寸并进行交易，为该公司提供投资银行、财务顾问或者金融产品等相关服务或向该公司招揽业务。

华泰证券的销售人员、交易人员或其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。华泰证券没有将此意见及建议向报告所有接收者进行更新的义务。华泰证券的资产管理部门、自营部门以及其他投资业务部门可能独立做出与本报告中的意见或建议不一致的投资决策。投资者应当考虑到华泰证券及/或其相关人员可能存在影响本报告观点客观性的潜在利益冲突。投资者请勿将本报告视为投资或其他决定的唯一信赖依据。有关该方面的具体披露请参照本报告尾部。

本报告并非意图发送、发布给在当地法律或监管规则下不允许向其发送、发布的机构或人员，也并非意图发送、发布给因可得到、使用本报告的行为而使华泰证券违反或受制于当地法律或监管规则的机构或人员。

本报告版权仅为华泰证券所有。未经华泰证券书面许可，任何机构或个人不得以翻版、复制、发表、引用或再次分发他人（无论整份或部分）等任何形式侵犯华泰证券版权。如征得华泰证券同意进行引用、刊发的，需在允许的范围内使用，并需在使用前获取独立的法律意见，以确定该引用、刊发符合当地适用法规的要求，同时注明出处为“华泰证券研究所”，且不得对本报告进行任何有悖原意的引用、删节和修改。华泰证券保留追究相关责任的权利。所有本报告中使用的商标、服务标记及标记均为华泰证券的商标、服务标记及标记。

中国香港

本报告由华泰证券股份有限公司或其关联机构制作，在香港由华泰金融控股（香港）有限公司向符合《证券及期货条例》及其附属法律规定的机构投资者和专业投资者的客户进行分发。华泰金融控股（香港）有限公司受香港证券及期货事务监察委员会监管，是华泰国际金融控股有限公司的全资子公司，后者为华泰证券股份有限公司的全资子公司。在香港获得本报告的人员若有任何有关本报告的问题，请与华泰金融控股（香港）有限公司联系。

香港-重要监管披露

- 华泰金融控股（香港）有限公司的雇员或其关联人士没有担任本报告中提及的公司或发行人的高级人员。
- 有关重要的披露信息，请参华泰金融控股（香港）有限公司的网页 https://www.htsc.com.hk/stock_disclosure 其他信息请参见下方 “美国-重要监管披露”。

美国

在美国本报告由华泰证券（美国）有限公司向符合美国监管规定的机构投资者进行发表与分发。华泰证券（美国）有限公司是美国注册经纪商和美国金融业监管局（FINRA）的注册会员。对于其在美国分发的研究报告，华泰证券（美国）有限公司根据《1934年证券交易法》（修订版）第15a-6条规定以及美国证券交易委员会人员解释，对本研究报告内容负责。华泰证券（美国）有限公司联营公司的分析师不具有美国金融监管（FINRA）分析师的注册资格，可能不属于华泰证券（美国）有限公司的关联人员，因此可能不受 FINRA 关于分析师与标的公司沟通、公开露面和所持交易证券的限制。华泰证券（美国）有限公司是华泰国际金融控股有限公司的全资子公司，后者为华泰证券股份有限公司的全资子公司。任何直接从华泰证券（美国）有限公司收到此报告并希望就本报告所述任何证券进行交易的人士，应通过华泰证券（美国）有限公司进行交易。

美国-重要监管披露

- 分析师卢炯、何康本人及相关人士并不担任本报告所提及的标的证券或发行人的高级人员、董事或顾问。分析师及相关人士与本报告所提及的标的证券或发行人并无任何相关财务利益。本披露中所提及的“相关人士”包括 FINRA 定义下分析师的家庭成员。分析师根据华泰证券的整体收入和盈利能力获得薪酬，包括源自公司投资银行业务的收入。
- 华泰证券股份有限公司、其子公司和/或其联营公司，及/或不时会以自身或代理形式向客户出售及购买华泰证券研究所覆盖公司的证券/衍生工具，包括股票及债券（包括衍生品）华泰证券研究所覆盖公司的证券/衍生工具，包括股票及债券（包括衍生品）。
- 华泰证券股份有限公司、其子公司和/或其联营公司，及/或其高级管理层、董事和雇员可能会持有本报告中所提到的任何证券（或任何相关投资）头寸，并可能不时进行增持或减持该证券（或投资）。因此，投资者应该意识到可能存在利益冲突。

新加坡

华泰证券（新加坡）有限公司持有新加坡金融管理局颁发的资本市场服务许可证，可从事资本市场产品交易，包括证券、集体投资计划中的单位、交易所交易的衍生品合约和场外衍生品合约，并且是《财务顾问法》规定的豁免财务顾问，就投资产品向他人提供建议，包括发布或公布研究分析或研究报告。华泰证券（新加坡）有限公司可能会根据《财务顾问条例》第32C条的规定分发其在华泰证券内的外国附属公司各自制作的信息/研究。本报告仅供认可投资者、专家投资者或机构投资者使用，华泰证券（新加坡）有限公司不对本报告内容承担法律责任。如果您是非预期接收者，请您立即通知并直接将本报告返回给华泰证券（新加坡）有限公司。本报告的新加坡接收者应联系您的华泰证券（新加坡）有限公司关系经理或客户主管，了解来自或与所分发的信息相关的事宜。

评级说明

投资评级基于分析师对报告发布日后6至12个月内行业或公司回报潜力（含此期间的股息回报）相对基准表现的预期（A股市场基准为沪深300指数，香港市场基准为恒生指数，美国市场基准为标普500指数，台湾市场基准为台湾加权指数，日本市场基准为日经225指数，新加坡市场基准为海峡时报指数，韩国市场基准为韩国有价证券指数，英国市场基准为富时100指数，德国市场基准为DAX指数），具体如下：

行业评级

增持：预计行业股票指数超越基准

中性：预计行业股票指数基本与基准持平

减持：预计行业股票指数明显弱于基准

公司评级

买入：预计股价超越基准15%以上

增持：预计股价超越基准5%~15%

持有：预计股价相对基准波动在-15%~5%之间

卖出：预计股价弱于基准15%以上

暂停评级：已暂停评级、目标价及预测，以遵守适用法规及/或公司政策

无评级：股票不在常规研究覆盖范围内。投资者不应期待华泰提供该等证券及/或公司相关的持续或补充信息

法律实体披露

中国: 华泰证券股份有限公司具有中国证监会核准的“证券投资咨询”业务资格, 经营许可证编号为: 91320000704041011J

香港: 华泰金融控股(香港)有限公司具有香港证监会核准的“就证券提供意见”业务资格, 经营许可证编号为: AOK809

美国: 华泰证券(美国)有限公司为美国金融业监管局(FINRA)成员, 具有在美国开展经纪交易商业业务的资格, 经营业务许可编号为: CRD#:298809/SEC#:8-70231

新加坡: 华泰证券(新加坡)有限公司具有新加坡金融管理局颁发的资本市场服务许可证, 并且是豁免财务顾问, 经营许可证编号为: 202233398E

华泰证券股份有限公司**南京**

南京市建邺区江东中路228号华泰证券广场1号楼/邮政编码: 210019

电话: 86 25 83389999/传真: 86 25 83387521

电子邮件: ht-rd@htsc.com

深圳

深圳市福田区益田路5999号基金大厦10楼/邮政编码: 518017

电话: 86 755 82493932/传真: 86 755 82492062

电子邮件: ht-rd@htsc.com

北京

北京市西城区太平桥大街丰盛胡同28号太平洋保险大厦A座18层/

邮政编码: 100032

电话: 86 10 63211166/传真: 86 10 63211275

电子邮件: ht-rd@htsc.com

上海

上海市浦东新区东方路18号保利广场E栋23楼/邮政编码: 200120

电话: 86 21 28972098/传真: 86 21 28972068

电子邮件: ht-rd@htsc.com

华泰金融控股(香港)有限公司

香港中环皇后大道中99号中环中心53楼

电话: +852-3658-6000/传真: +852-2567-6123

电子邮件: research@htsc.com

<http://www.htsc.com.hk>

华泰证券(美国)有限公司

美国纽约公园大道280号21楼东(纽约10017)

电话: +212-763-8160/传真: +917-725-9702

电子邮件: Huatai@htsc-us.com

<http://www.htsc-us.com>

华泰证券(新加坡)有限公司

滨海湾金融中心1号大厦, #08-02, 新加坡 018981

电话: +65 68603600

传真: +65 65091183

<https://www.htsc.com.sg>

©版权所有2025年华泰证券股份有限公司